15기 정규세션 ToBig's 14기 고경태

# 모델 심화 Recurrent Neural Network

### References

먼저, 다음 오픈소스를 참고하여 강의자료를 만들었음을 밝힙니다. 설명이 부족한 부분은 아래의 링크에서 자세;히 공부하면 좋을 것 같습니다.

Idea Factory KAIST – 딥러닝 홀로서기 #26, #28

<u>Idea Factory KAIST – YouTube</u>

# nte nts

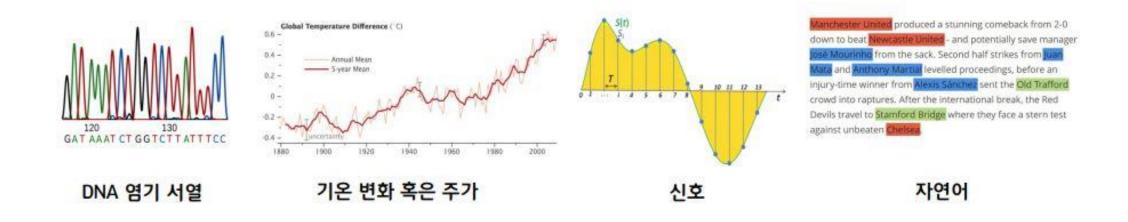
Unit	01		Sequential data
Unit	02		Vanilla RNN
Unit	03		LSTM and GRU
Unit	03		Seq2Seq and Attention

15기 정규세션 ToBig's 14기 고경태

# **Sequential data**

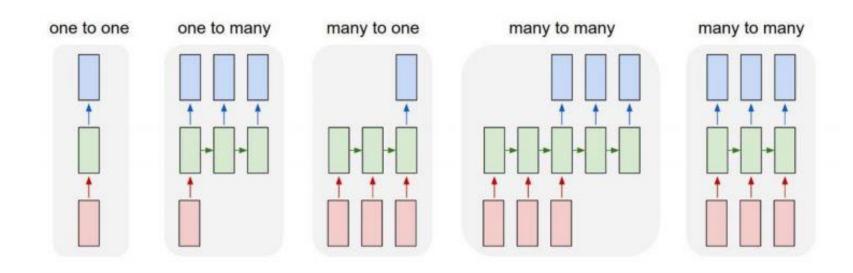
# 순차 데이터(Sequential data)

순서가 의미가 있으며, 순서가 달라질 경우 의미가 손상되는 데이터



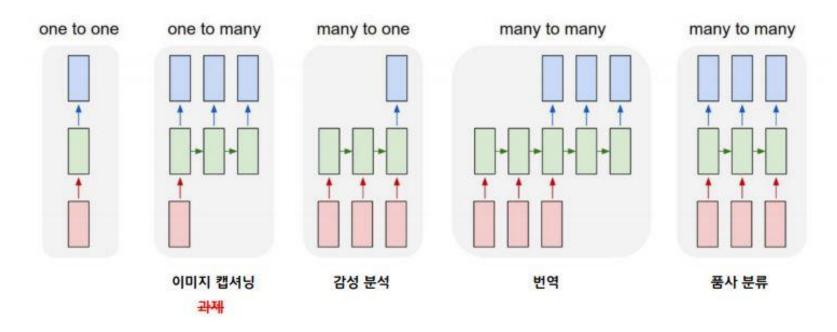
# 순차 데이터(Sequntial data)

다양한 태스크를 모델링할 수 있습니다.



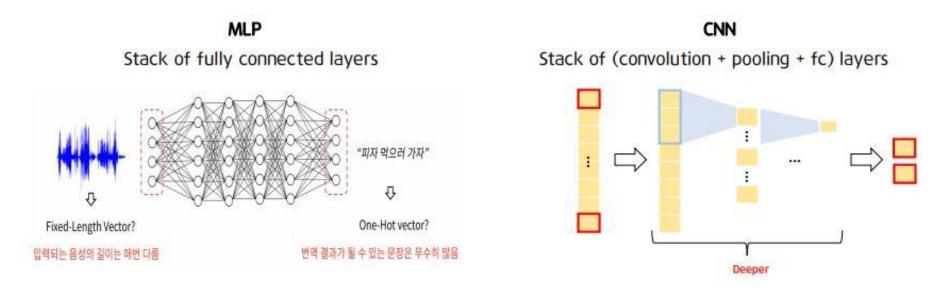
# 순차 데이터(Sequntial data)

다양한 태스크를 모델링할 수 있습니다.



# 순차 데이터(Sequntial data)

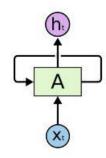
지금까지 배운 구조를 적용한다면...



Sequential data에 알맞은 구조가 있을까요?

15기 정규세션 ToBig's 14기 고경태

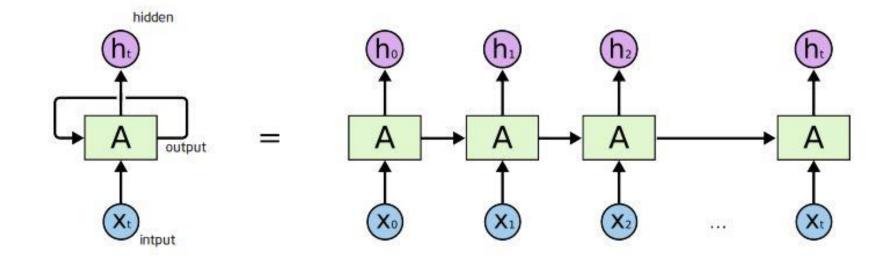
# Vanilla RNN



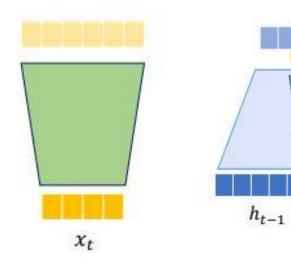
# Recurrent Neural Network(RNN) 순환 구조를 이루고 있는 인공 신경망

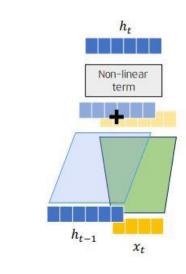
RNN의 핵심!

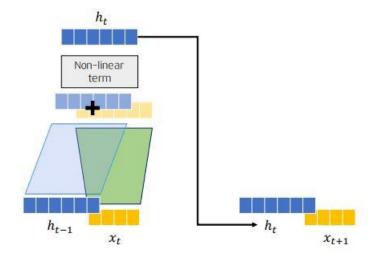
Hidden feature를 만들기 위해 현재 state의 input과 이전 state의 output을 사용합니다.



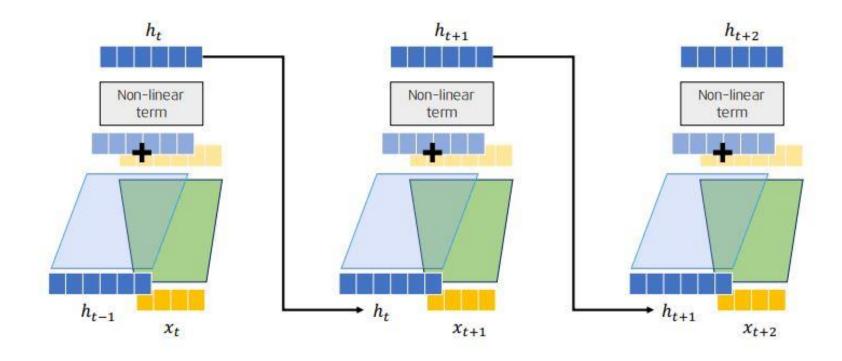
# Recurrent Neural Network(RNN) 내부를 뜯어보자!



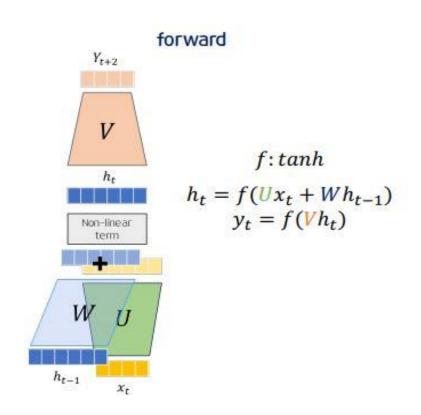




# Recurrent Neural Network(RNN) 내부를 뜯어보자!



## Recurrent Neural Network(RNN) 수식을 뜯어보자!

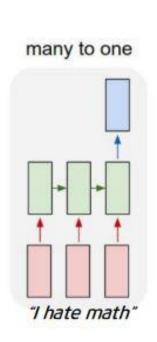


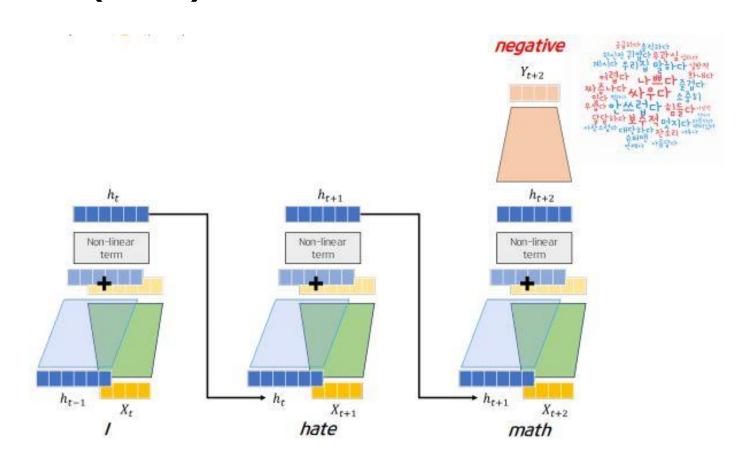
loss

$$Loss(\theta) = \sum_{t} loss(y_{true,t}, y_{pred,t})$$

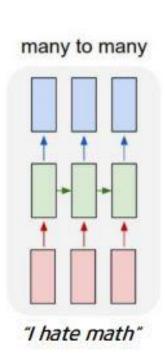
 $Classification \rightarrow CrossEntropy$  $Regression \rightarrow MSE$ 

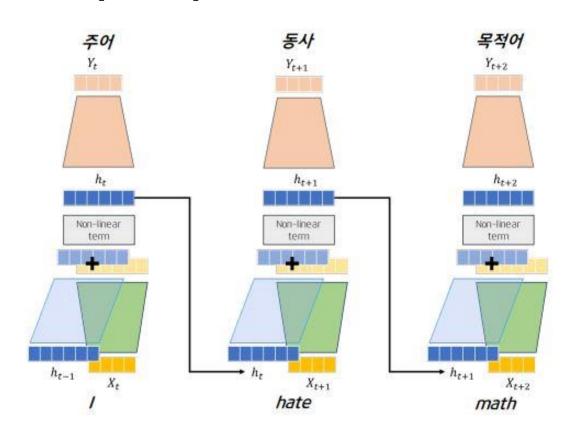
# Recurrent Neural Network(RNN) 적용해보자!



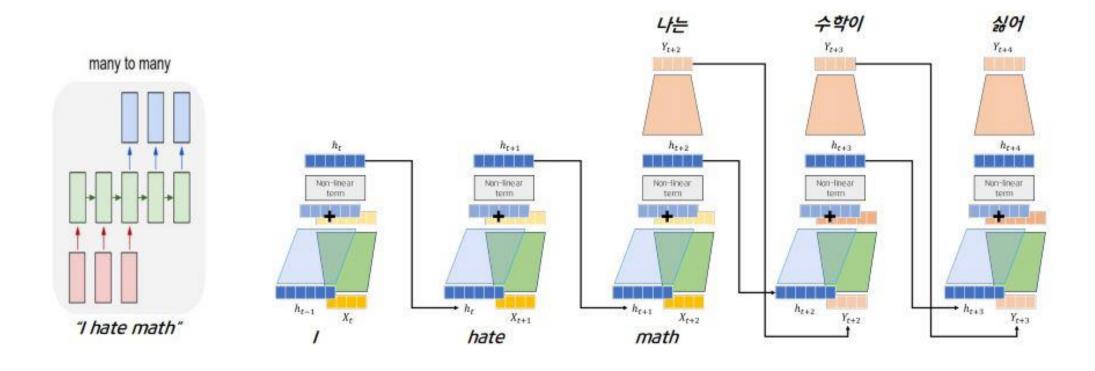


# Recurrent Neural Network(RNN) 적용해보자!

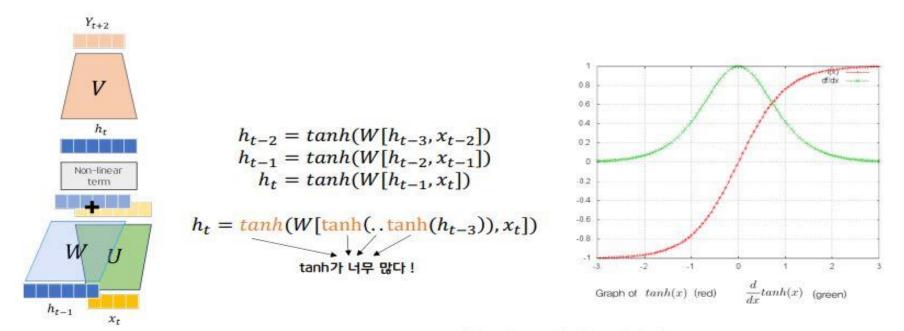




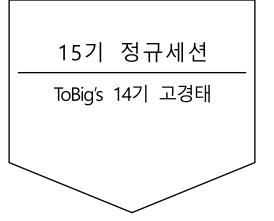
# Recurrent Neural Network(RNN) 적용해보자!



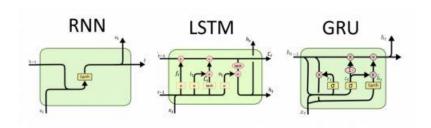
# Recurrent Neural Network(RNN) Vanishing gradient



Vanilla RNN로 long sequence를 학습하는 것은 힘듭니다 :(

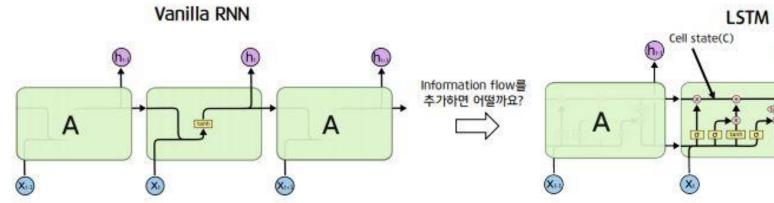


# **LSTM** and **GRU**



# Long Short Term Memory Network Va

Vanilla RNN vs LSTM



 $h_t$ : 이전 step의 정보 저장 + output 역할을 하자

 $h_t$  의 역할이 너무 많습니다.

C(cell state): 남길 건 남기고, 잊어버릴 건 잊어버리고, 새로 추가할 건 추가하자 중요한 정보만 계속 흘러가도록!

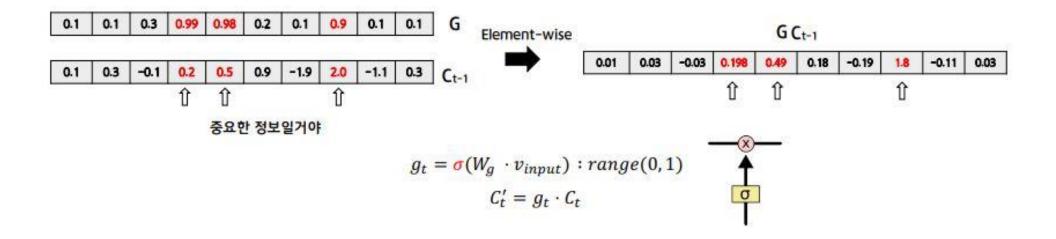
A

 $h_t$ : C 를 적당히 가공해서 내보내자

### **Gate**

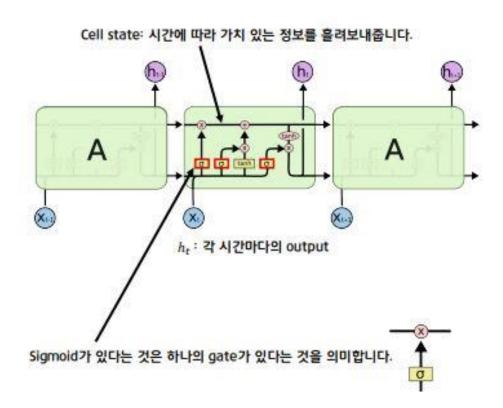
Element wise로 계수(coefficient)를 곱해주는 것

Control whether pass or block the information of each dimension with coefficient 0~1



# Long Short Term Memory Network

내부를 뜯어보자



<u>남길 건 남기고</u>, 잊어버릴 건 잊어버리고, 새로 추가할 건 추가해서 cell state에 중요한 정보만 계속 흘러가도록!

남길 건 남기고, <u>잊어버릴 건 잊어버리고</u>, 새로 추가할 건 추가해서 cell state에 중요한 정보만 계속 흘러가도록!

남길 건 남기고, 잊어버릴 건 잊어버리고, <u>새로 추가할 건 추가해서</u> cell state에 중요한 정보만 계속 흘러가도록!

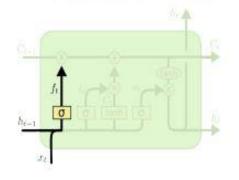


Gate!

# **Long Short Term Memory Network**

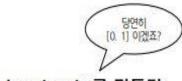
### 수식을 뜯어보자

① Forget gate를 만든다.

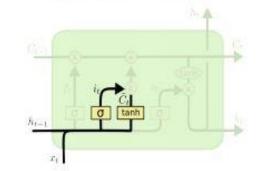


$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \ + \ b_f\right)$$

 $C_{t-1}$  에서 불필요한 정보를 지웁니다.



② Input gate를 만든다.



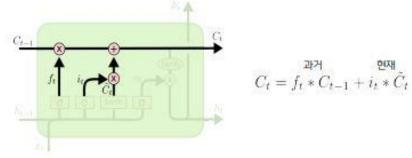
$$\begin{split} i_t &= \sigma\left(W_i \cdot [h_{t-1}, x_t] \ + \ b_i\right) \\ \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] \ + \ b_C) \end{split}$$

 $C_{t-1}$ 에 새로운 input  $x_t$ 와  $h_{t-1}$ 를 보고 중요한 정보를 넣습니다.

# **Long Short Term Memory Network**

수식을 뜯어보자

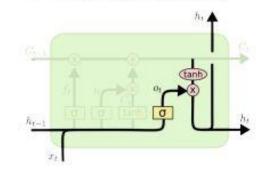
### ③ Cell state를 업데이트 한다.



$$f_t$$
 를 이용해서  $C_{t-1}$  의 일부 정보를 날리고,

 $i_t$  를 이용해서  $\widetilde{C}_t$  정보를 추가합니다.

### ④ output gate를 만든다.



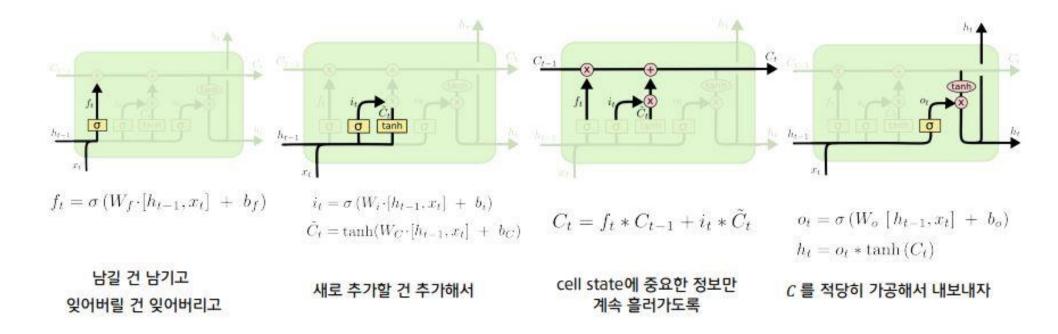
$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t * \tanh(C_t)$$

 $C_t$ 를 적절히 가공해  $h_t$ 를 만듭니다.

가공은 output gate  $o_t$ 로 합니다.

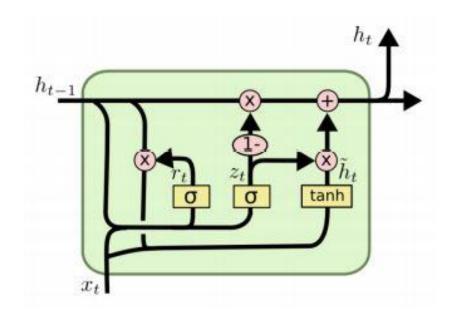
# Long Short Term Memory Network 정리

남길 건 남기고, 잊어버릴 건 잊어버리고, 새로 추가할 건 추가해서 cell state에 중요한 정보만 계속 흘러가도록!



# Gate Recurrent Unit LSTM VS GRU

LSTM의 간소화



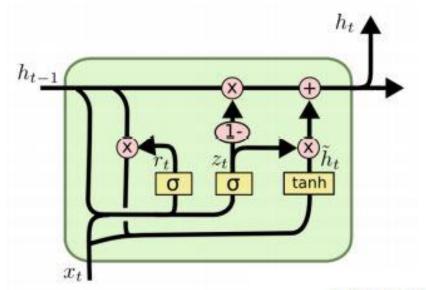
탄생 배경: LSTM은 gate 수가 너무 많습니다. 이것을 줄일 수 없을까요?

### GRU의 특징:

- cell state가 없고, hidden state만 존재함.
  - Forget + input gate를 결합시킴.
    - Reset gate를 추가함.

여전히 vanishing gradient를 해결할 수 있을까요?

# Gate Recurrent Unit 수식을 뜯어보자



$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r)$$

$$\widetilde{h_t} = tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h)$$

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z)$$

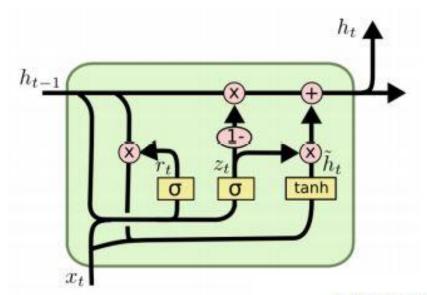
$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \widetilde{h_t}$$

1. Reset gate를 계산해서 임시  $h_t$ 를 만든다.

2. Update gate를 통해  $h_{t-1}$ 과  $\widetilde{h_t}$  간의 비중을 결정한다.

 $3. Z_t$ 를 이용해 최종  $h_t$ 를 계산한다.

# Gate Recurrent Unit 수식을 뜯어보자



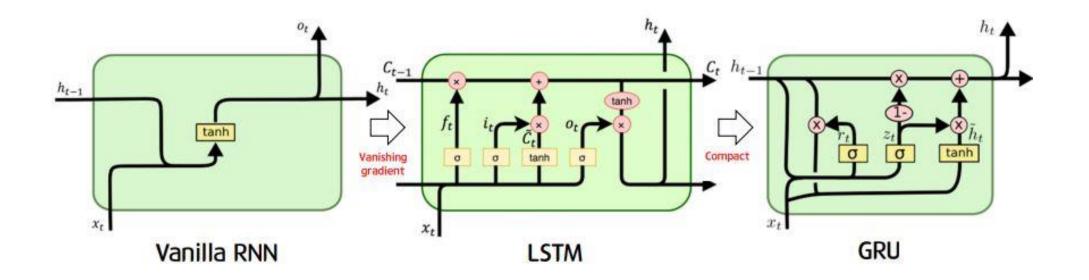
$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r)$$
 0에 가까운 값이 되면 'reset'이 되어. 새로운 input이 시작이 될 수 있다.  $\widetilde{h_t} = tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h)$  
$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z)$$
 과거와 현재 정보의 비중을 결정 
$$h_t = (1-z_t) \odot h_{t-1} + z_t \odot \widetilde{h_t}$$
 past current

1. Reset gate를 계산해서 임시  $h_t$ 를 만든다.

2. Update gate를 통해  $h_{t-1}$ 과  $\widetilde{h_t}$  간의 비중을 결정한다.

 $3. Z_t$ 를 이용해 최종  $h_t$ 를 계산한다.

# **Summary**



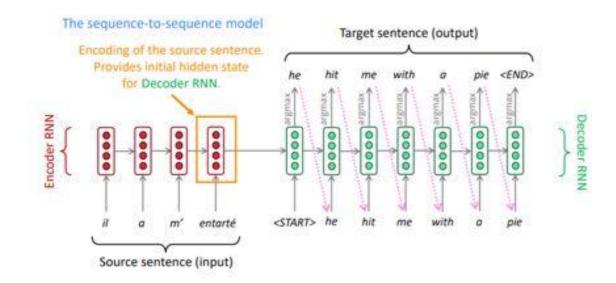
LSTM과 GRU는 Vanishing gradient를 어떻게 해결하려고 했을까요?

15기 정규세션

ToBig's 14기 고경태

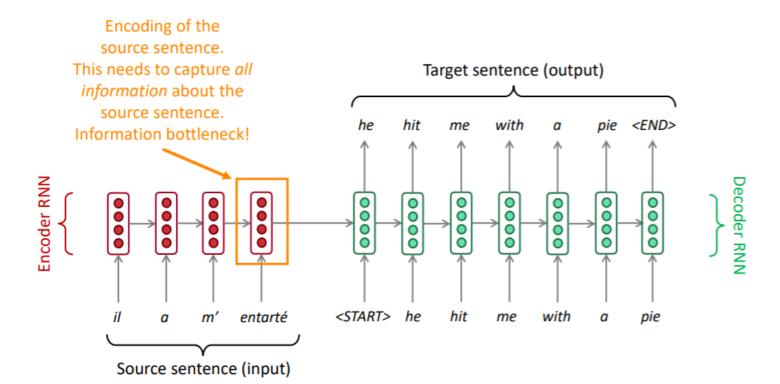
# **Attention**

# Sequence-to-sequence



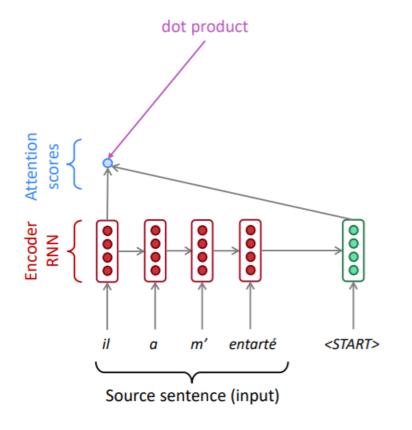
두개의 RNN을 포함한 seq-to-seq

# Sequence-to-sequence: the bottleneck problem



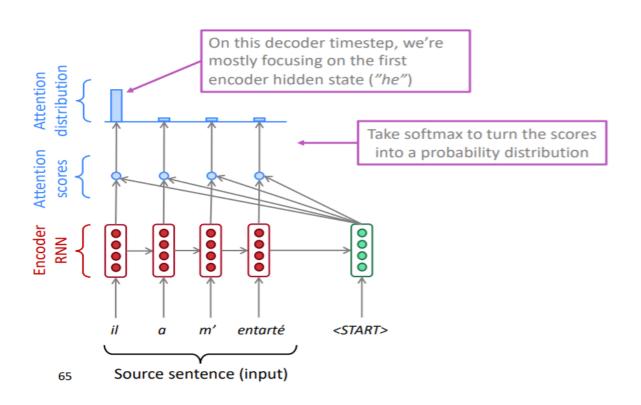
맨 끝에서 모든 정보를 캡쳐 강요→ 너무 많은 압력 → 병목문제

# Sequence-to-sequence with attention





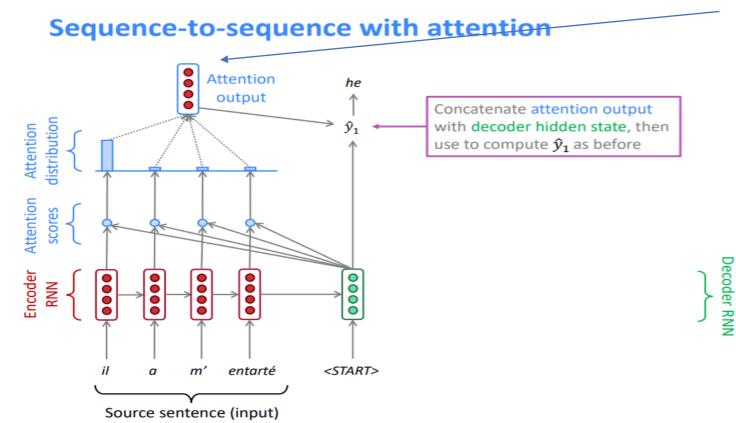
# Sequence-to-sequence with attention

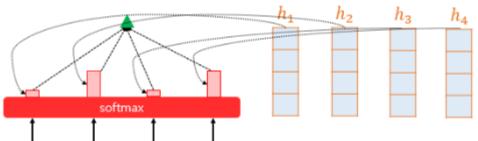


Decoder RNN

모든 인코더의 step마다 반복! Attention을 주는 것

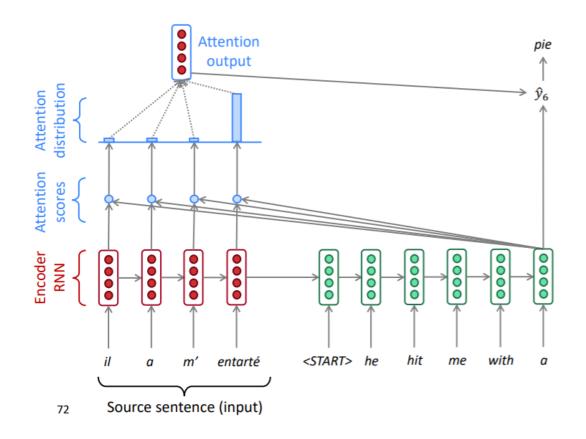
Sequence-to-sequence with attention





Attention의 output과 decode의 hidden state의 결합 → y1(hat)을 계산

# Sequence-to-sequence with attention

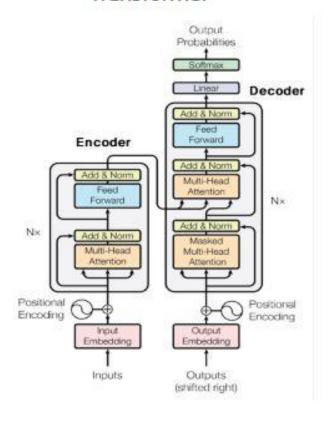


decoder에서도 같은 행동을 반복!

### Unit 05 | Transformer

### Pretrained model

### Transformer



### Keyword

- ✓ Masked attention
- ✓ Multi head attention
  - ✓ Self attention
- ✓ Positional encoding

### 과제 소개

# 과제. ResNet / Transformer 논문 리뷰 (택1)

둘 중 하나를 선택해서 리뷰해주세요! (hwp, word, markdown 등 형식은 자유입니다.) 제시한 키워드를 바탕으로 작동원리를 설명하고, 사용하는 이유를 중심으로 설명주세요. 다른 리뷰 글을 참고하셔도 괜찮지만, 그대로 가져왔다고 생각되는 경우 과제 반려합니다. (참고하신 글은 꼭 reference로 달아주세요~)

### 과제 소개

### 논문 리뷰 Keyword

### < ResNet >

(Deep residual learning)

- ✓ Degradation Problem
- √ Residual Learning
- √ Skip Connection
- √ Identity mapping

### Transformer >

(Attention is all you need)

- √ Masked attention
- ✓ Self attention
- ✓ Multi head attention
- √ Positional encoding

# Q & A

들어주셔서 감사합니다.